

Classification supervisée 'objet' (OBIA)

Random Forest

Quartier de la Roberstau - Strasbourg

20 avril 2026



Figure 1 : Carte multi-classe avec saisie par points (Bandes + NDVI + Entropy)

Enseignant référant : Romain Wenger

Enseignement : Traitement d'images niveau 1

Niveau : M1 OTG

Introduction

La cartographie de l'occupation du sol en milieu urbain représente un enjeu majeur pour la gestion des territoires, la planification urbaine et le suivi environnemental. L'essor des capteurs satellitaires à très haute résolution spatiale, tels que Pléiades avec sa résolution de 50 centimètres, ouvre des perspectives inédites pour la description fine du tissu urbain, permettant de distinguer des objets jusqu'alors indiscernables depuis l'espace. Cependant, l'exploitation de ces données par des méthodes de classification pixel à pixel se heurte rapidement à leurs propres limites : la richesse géométrique et texturale de l'image n'est pas mobilisée, et la classification produit fréquemment un résultat fragmenté, peu cohérent avec la réalité du terrain.

Face à ce constat, l'analyse d'images orientée objet — connue sous l'acronyme OBIA pour *Object-Based Image Analysis* — s'est progressivement imposée comme une alternative plus adaptée à l'imagerie de très haute résolution. Plutôt que de traiter chaque pixel de manière indépendante, cette approche repose sur une segmentation préalable de l'image en régions homogènes, les objets, qui constituent l'unité d'analyse de base. Blaschke (2010) a formalisé les fondements de cette démarche en télédétection, en montrant que l'intégration de descripteurs spectraux, géométriques et contextuels permettait d'améliorer significativement la qualité des classifications sur des images à haute résolution. Quelques années plus tard, Blaschke et al. (2014) ont prolongé cette réflexion en proposant le concept de GEOBIA (*Geographic Object-Based Image Analysis*), qui inscrit l'objet dans un cadre géographique plus large, intégrant les relations spatiales entre entités et ouvrant la voie à une analyse multi-échelle du territoire.

Ce travail s'inscrit dans la continuité de ces travaux, en appliquant une classification OBIA supervisée à une image Pléiades couvrant une zone urbaine de Strasbourg. Le protocole mis en œuvre repose sur une segmentation par l'algorithme LargeScaleMeanShift, suivie d'une extraction d'attributs spectraux, texturaux et altimétriques, et d'un apprentissage par la méthode Random Forest. Trois objectifs structurent la démarche : produire une classification multi-classe de l'occupation du sol, développer une classification binaire orientée vers la détection des bâtiments, et comparer les performances des deux approches afin d'évaluer l'intérêt d'une nomenclature simplifiée pour une classe d'intérêt spécifique.

Table des matières

Introduction.....	2
Méthodologie.....	4
Données.....	4
Zone d'étude.....	5
Organigramme de traitements.....	7
Segmentation.....	8
Extraction des attributs.....	9
Stratégie d'échantillonnage.....	10
Saisie pour la classification multi-classe.....	10
Saisie pour la classification binaire.....	11
Protocole de test.....	12
Résultats.....	13
Résultats classification multi-classe.....	13
Saisie par polygone.....	13
Carte multi-classe avec saisie par polygones (Bandes + NDVI + Entropy).....	14
Saisie par points.....	15
Carte multi-classe avec saisie par points (Bandes + NDVI + Entropy).....	16
Résultats classification binaire.....	17
Saisie par polygone.....	17
Carte binaire avec saisie par polygone (Bandes + NDVI + Entropy + MNE).....	18
Carte binaire avec saisie par polygone (Bandes + NDVI + Entropy).....	19
Saisie par points.....	20
Carte binaire avec saisie par points (Bandes + Haralick).....	21
Validation OCS.....	22
Discussion.....	23
Conclusion.....	24
Bibliographie.....	24

Méthodologie

Données

Notre donnée principale est une image raster multispectrale Pléiades à 4 bandes spectrales (bleu b0, vert b1, rouge b2 et proche infrarouge b3) avec une résolution de 0,50 m. Cette image date de 2016. Les dimensions de l'image sont de 1km sur 1km.

Nous utilisons une deuxième donnée raster exogène, celle du Modèle Numérique d'Élévation (MNE) des bâtiments issu de notre professeur Romain Wenger.

Le système de projection l'image pléiade et le MNE sont fournis avec un système de projection EPSG 3948. Pour une meilleure conformité, notamment avec l'OCS Grand Est du Bas-Rhin qui dispose d'un Lambert93 EPSG 2154, nous avons décidé de convertir l'image pléiade et le MNE en EPSG 2154.

Nous avons téléchargé l'OCS Grand Est du Bas-Rhin pour l'année 2019 depuis le portail Géoservice de l'IGN, celle-ci nous a permis de comparer nos résultats de classification avec une donnée de référence. L'année 2019 est celle la plus proche de 2016 que l'on ai pu télécharger sur le site.

Nous avons reclassifié cette dernière sur QGIS via le champ lib_n2 pour l'associer le plus fidèlement possible notre classification multi-classe :

Classe	Catégories (lib_n2)
1	Habitat, Activités économiques, Equipements et infrastructures collectives
2	Forêts
3	Espaces verts urbains, Terres arables, Autres zones agricoles, Cultures permanentes, Milieux naturels liés à l'eau
4	Infrastructures et superstructures des réseaux de transport
5	Espaces en mutation, Espaces ouverts urbains
6	Surfaces en eau

La couche a ensuite été rasterisée à une résolution de 0,5 m sur l'emprise de l'image Pléiade pour une comparaison pixel par pixel juste.

L'intégration du MNE mérite d'être précisée sur le plan méthodologique. Celui-ci n'a pas été incorporé directement dans le stack image servant à la segmentation. Il a plutôt été mobilisé comme attribut exogène au niveau objet, selon la même logique que le NDVI ou les indices de Haralick. Le raster d'élévation a d'abord été nettoyé afin de remplacer les valeurs NoData par zéro, de manière à ce que les polygones ne recouvrant aucun bâtiment reçoivent une hauteur nulle plutôt qu'une valeur manquante incompatible avec l'algorithme d'apprentissage. Une statistique zonale de moyenne a ensuite été calculée pour chaque polygone de segmentation via l'outil Statistiques de Zone de QGIS, produisant la colonne height_clean dans la table attributaire. Cette variable a finalement été sélectionnée parmi les features lors du paramétrage du TrainVectorClassifier, au même titre que les descripteurs spectraux et texturaux. Le MNE intervient donc non comme une image supplémentaire mais comme un descripteur objet intégré directement dans le vecteur d'apprentissage.

Zone d'étude

La zone d'étude porte sur la partie Nord du quartier de la Roberstau, lui-même au Nord de la ville de Strasbourg. D'après le libellé de catégorie 1 de l'OCS Grand Est (*Figure 3*), il s'agit d'une zone recouvrant en majorité des surfaces périurbaines, avec quelques emprises pavillonnaires et commerciales. L'image est traversée par deux cours d'eau : la Mulhwasser en orientation Sud-Nord et l'Ill en orientation Ouest-Est. On retrouve aussi quelques zones de forêts, notamment le long des cours d'eau, ainsi que des surfaces agricoles, situées plutôt au Nord de l'image.



Figure 2 : Image Pléiade brut (QGIS)




Figure 3 : Contexte géographique de la zone d'étude (QGIS)





Figure 4 : Classification d'ordre 1 de l'OCS Grand Est (QGIS)

Organigramme de traitement



Segmentation

Nous avons utilisé l'outil Orfeo ToolBox (OTB) dans QGIS pour effectuer notre segmentation. Nous avons retenu l'algorithme de segmentation watershed plutôt que meanshift. L'algorithme watershed permet de dégager des surfaces beaucoup plus homogènes, c'est à dire que les composantes de textures sont plus réalistes avec le terrain et les proportions sont mieux respectées (figure 5). En effet, la segmentation watershed est assez « brouillonne » (beaucoup de bruits) par endroits, notamment en repérant et en segmentant des objets très petits.

Néanmoins, et malgré de nombreux essais visant à atténuer ce bruit parasite sur la segmentation watershed, il est quasiment impossible de s'en débarrasser complètement, ce qui met en évidence les limites de cet algorithme. En effet, si l'on augmente le seuil de profondeur pour supprimer le bruit, nous perdons des composantes significatives de la segmentation, et si l'on réduit le seuil, le bruit devient trop important et les composantes perdent en significativité.

De plus, la THRS Pléiades nécessite des segments fins pour capturer les bâtiments individuels, un seuil trop grand fusionnerait les objets spectralement distincts. Un compromis est donc nécessaire.

À noter que le terme de composante est utilisé non pas comme une classe d'occupation du sol mais plutôt comme un objet homogène, d'au moins quelques mètres de largeur ou/et de hauteur, ce qui le différencie d'objet plus petit peu homogène dit bruit.

Dans cette démarche itérative, nous avons choisi une segmentation watershed avec 0,003 pour la profondeur du seuil et 0,1 pour de le Flood level, avec un produit de traitement en sortie raster.

Au final, la segmentation nous offre 166 654 entités sur notre emprise, un nombre très élevé que l'on pourra critiquer lors de nos résultats dans la partie discussion.



Watershed



Meanshift




Figure 5 : Différentiation entre les algorithmes de segmentation watershed et meanshift

Extraction des attributs

La phase d'extraction des attributs constitue l'étape centrale de l'approche objet, dans la mesure où la qualité de la classification dépend directement de la richesse des descripteurs associés à chaque segment.

Dans un premier temps, l'outil LSMSVectorization d'OTB a été appliqué sur le résultat de la segmentation afin de calculer, pour chaque polygone, la moyenne et la variance des valeurs de réflectance de chaque bande spectrale (meanB0 à meanB3, varB0 à varB3). La moyenne renseigne sur la signature spectrale moyenne de l'objet, tandis que la variance traduit son homogénéité interne — un bâtiment à toit plat présentera une variance faible, contrairement à une canopée arborée dont la texture est naturellement plus irrégulière.

Dans un second temps, trois indices de texture Haralick ont été calculés à partir de l'outil Texture Analysis d'OTB, appliqué sur la bande panchromatique synthétisée à partir du stack Pléiades. Cet outil implémente la matrice de cooccurrence de Haralick (1973), qui caractérise la distribution spatiale des niveaux de gris au sein d'une fenêtre glissante. Trois descripteurs ont été retenus : le contraste, qui mesure l'écart entre pixels voisins et permet de distinguer des surfaces lisses comme les routes des surfaces rugueuses comme les toitures ; l'entropie, qui quantifie le désordre textural et s'avère particulièrement discriminante pour différencier les formations arborées des surfaces imperméables ; et la dissimilarité, proche du contraste mais moins sensible aux valeurs extrêmes, qui apporte une information complémentaire sur l'hétérogénéité locale. Ces trois descripteurs ont été préférés aux autres indices Haralick disponibles (énergie, homogénéité, corrélation) car ils présentent une plus grande variabilité inter-classes sur les milieux urbains et sont moins redondants entre eux.

Le NDVI a également été calculé pour chaque date selon la formule classique $(PIR - R) / (PIR + R)$, afin d'introduire une dimension séparant la végétation du bâti et du sol nu, information non accessible directement depuis les bandes spectrales individuelles.

L'ensemble de ces rasters a ensuite été joint aux polygones de segmentation via l'outil Statistiques de Zone de QGIS, permettant d'obtenir pour chaque objet la valeur moyenne de chaque indice exogène.

Enfin, une jointure spatiale a été réalisée entre les polygones de segmentation enrichis et les couches d'échantillons d'entraînement et de validation, afin d'associer à chaque polygone d'apprentissage son identifiant de classe. Le modèle Random Forest a alors été entraîné via l'outil TrainVectorClassifier d'OTB, en renseignant les colonnes attributaires correspondant aux features sélectionnées, la couche de validation et le champ contenant les identifiants de classe.

Stratégie d'échantillonnage

Nous avons testé deux méthodes de saisie différentes pour l'apprentissage des modèles multi-classes et binaire : polygone et points.

La saisie d'une couche d'apprentissage et de contrôle par polygone est intéressante car elle permet d'attribuer des milliers de pixels à chaque classe, ce qui permet en théorie d'aider le modèle à mieux identifier des zones homogènes et à mieux les différencier. Les polygones ont aussi l'avantage de couvrir la variabilité intra-classe tels que les toits clairs et sombres ou les arbres isolés et les bosquets.

Cela demande néanmoins une grande attention lors de la saisie de ces polygones, afin d'avoir des polygones homogènes, de taille modeste et des nombres de pixels relevés entre chaque classe assez égaux pour ne pas créer de sur et sous-apprentissage de classe.

La saisie par points est théoriquement et statistiquement moins efficace, mais elle comporte l'avantage de ne relever qu'un pixel par point relevé, ce qui empêche grandement l'erreur de classe attribué pour ce pixel. Néanmoins, cette méthode peut se révéler peu fiable si les points sont trop peu nombreux et proche spectralement en intra-classe.

Pour chacune des saisies des couches d'apprentissage et de contrôle, nous avons respecté un ratio par 2/3 : 2/3 apprentissage et 1/3 contrôle, réparti entre 6 classes pour la classification multi et 2 classes pour la classification binaire. Il s'agit d'un ratio qui se rapproche des standard en machine learning autour des 70/30, garantissant une évaluation indépendante.

Saisie pour la classification multi-classe

Il y a moins de polygones dans les classes Sol nu et Eau car l'image de référence ne comportait pas assez de surface dans ces classes pour étendre la saisie.

<i>Classe / Légende</i>	<i>Num classe</i>	<i>Nombre de POLYGONE apprentissage</i>	<i>Nombre de POLYGONE contrôle</i>
Bâtiment	1	30	10
Forêt / arbre	2	30	10
Prairie / gazon	3	30	10
Route	4	30	10
Sol nu	5	15	5
Eau	6	15	5
Total	/	160	54

Figure 6 : Répartition des polygone par classe pour la saisie multi-classe

<i>Classe / Légende</i>	<i>Num classe</i>	<i>Nombre de POINTS apprentissage</i>	<i>Nombre de POINTS contrôle</i>
Bâtiment	1	30	10
Forêt / arbre	2	30	10
Prairie / gazon	3	30	10
Route	4	30	10
Sol nu	5	30	10
Eau	6	30	10
Total	/	180	60

Figure 7 : Répartition des points par classe pour la saisie multi-classe

Saisie pour la classification binaire

<i>Classe / Légende</i>	<i>Num classe</i>	<i>Nombre de POLYGONE apprentissage</i>	<i>Nombre de POLYGONE contrôle</i>
Bâtiment	1	60	20
Autre	2	60	20
Total	/	160	60

Figure 8 : Répartition des polygone par classe pour la saisie binaire

<i>Classe / Légende</i>	<i>Num classe</i>	<i>Nombre de POLYGONE apprentissage</i>	<i>Nombre de POLYGONE contrôle</i>
Bâtiment	1	60	20
Autre	2	60	20
Total	/	160	60

Figure 9 : Répartition des points par classe pour la saisie binaire

Protocole de test

Les tests de classification supervisée ont été réalisés par le modèle de classifieur Random Forest, il s'agit d'un modèle robuste aux données à haute résolution, capable de gérer des variables corrélées et fournit une importance aux variables sélectionnées (*Figure 8*).

Chacun de ces test sera effectués à la fois pour la saisie par polygone et la saisie points et par la saisie binaire.

Test effectués	<i>Attributs d'apprentissage du modèle</i>				
/	Stack Pléiade	Haralick			
/	Moyenne et variances des bandes spectrales	NDVI	Entropy	Contraste	Dissimilarité
T1					
T2					
T3					
T4					
T5					
T6					
T7					
T8					

Compris
 Non-compris

Figure 8 : Tableau des attributs utilisés pour les différents tests.

Pour la classification binaire, nous avons adopté une démarche en deux temps, guidée par un souci d'efficacité et de rigueur progressive.

Une première série de sept tests a été conduite à partir d'échantillons ponctuels, en faisant varier les combinaisons d'attributs spectraux et texturaux. Ce protocole de tests rapide, bien que limité par le faible effectif de points de contrôle par classe, nous a permis d'identifier les descripteurs les plus pertinents pour discriminer les bâtiments du reste de l'occupation du sol, avant d'engager un travail de digitalisation plus coûteux en temps.

Sur la base de ces résultats préliminaires, deux tests ont été reconduits avec des échantillons polygonaux, dont la validation s'avère statistiquement plus solide puisqu'elle couvre une plus grande variabilité intra-classe. Le premier test, sans MNE, constituait notre référence spectro-texturale. Le second y ajoutait la dimension altimétrique via le Modèle Numérique d'Élévation des bâtiments.

Résultats

Résultats classification multi-classe

Saisie par polygone

Test	Attributs	F-score par classe (%)						F-score moyen %	Rang
		Bati	Foret	Prairie	Route	Sol nu	Eau		
T7	Bandes + NDVI + Entropy	97	99.3	54.3	62.5	81.6	85.7	80.1	1
T6	Bandes + NDVI + Haralick	97	99.3	60.7	63.2	82.1	75	79.5	2
T8	Bandes + Contraste + Entropy	97	99.2	44.3	66.7	79.8	75	77	3
T3	Bandes + Entropy	97	99.2	39.7	58.8	81.4	75	75.2	4
T4	Bandes + Contraste	96.6	99.2	42	33.3	79	75	70.9	5
T5	Bandes + Dissimilarite	96.7	99.2	44.8	0	81.1	75	66.1	6
T2	Bandes seules	96.5	99.1	35.7	0	80.1	66.7	63	7
T1	Bandes + NDVI	96.6	99.1	31	0	80.2	66.7	62.3	8

Figure 9 : Résultats classification multi-classe avec échantillonnage par polygone

Les résultats obtenus en multi-classe avec un échantillonnage par polygones montrent que la combinaison *bandes + NDVI + entropy* est la plus performante, avec un F-score moyen de 80,1 %. Cette configuration confirme l'intérêt d'ajouter des attributs texturaux à l'information spectrale brute. Les classes *bâti* et *forêt* sont très bien discriminées, avec des scores proches de 97 à 99 %, ce qui traduit une signature relativement stable de ces objets.

En revanche, les performances chutent nettement pour les classes *prairie* et *route*, qui restent les plus difficiles à séparer. Cette baisse s'explique probablement par leur forte variabilité interne et par des ressemblances spectrales avec d'autres surfaces, notamment les sols nus ou certaines zones végétalisées peu denses. Globalement, ce tableau montre que l'approche multi-classe fonctionne bien pour les classes visuellement structurées, mais devient plus incertaine dès que les objets présentent des transitions ou des textures proches.

Carte multi-classe avec saisie par polygones (Bandes + NDVI + Entropy)

Classification orientée objet multi-classe — Echantillonnage par polygones
Attributs : bandes spectrales + NDVI + Entropie Haralick | Random Forest | F-score
moyen : 80.1%



Légende multi-classe

-  Batiments
-  Couverture forestière / arbres
-  Prairie / gazon
-  Routes
-  Sol nu
-  Eau

0 100 200 m



Auteur : Arthur Viry

Sources : Image satellitaire Pléiades, © Airbus Defence & Space, [2016], résolution spatiale 50 cm

Figure 10 : Carte multi-classe avec saisie par polygones (Bandes + NDVI + Entropy) (QGIS)

Saisie par points

Test	Attributs	F-score par classe (%)						F-score moyen %	Rang
		Bâtiment	Foret	Prairie	Route	Sol nu	Eau		
T7	Bandes + NDVI + Entropy	100	94.7	95.2	100	100	100	98.3	1
T5	Bandes + Dissimilarite	100	95.2	94.7	100	100	100	98.3	2
T3	Bandes + Entropy	100	90	90	100	100	100	96.7	3
T8	Bandes + Contraste + Entropy	94.7	94.7	90.9	100	100	100	96.7	4
T1	Bandes seules	95.2	94.7	95.2	94.7	100	100	96.6	5
T6	Bandes + NDVI + Haralick	100	90.9	88.9	100	100	100	96.6	6
T4	Bandes + Contraste	94.7	94.7	95.2	95.2	100	100	96.6	7
T1	Bandes + NDVI	95.2	90.9	88.9	94.7	100	100	95	8

Figure 11 : Résultats classification multi-classe avec échantillonnage par points

Le tableau basé sur un échantillonnage par points présente des scores très élevés, compris entre 95,0 et 98,3 % de F-score moyen selon les combinaisons testées. À première vue, ces résultats semblent meilleurs que ceux obtenus avec les polygones, mais ils doivent être interprétés avec prudence. Le faible nombre de points par classe rend la validation moins robuste et peut produire une vision un peu trop optimiste de la qualité réelle de la classification. Plusieurs classes atteignent même 100 %, ce qui suggère que l'échantillon de contrôle ne couvre sans doute pas toute la variabilité spatiale du terrain.

Malgré cela, on retrouve la même tendance générale : l'ajout d'attributs comme le NDVI, l'entropy ou la dissimilarité améliore légèrement les performances par rapport aux bandes seules. Ce tableau met donc surtout en évidence une bonne séparabilité théorique des classes, mais avec une fiabilité statistique plus limitée que dans le cas des polygones.

Carte multi-classe avec saisie par points (Bandes + NDVI + Entropy)

Classification orientée objet multi-classe — Echantillonnage par points
Attributs : bandes spectrales + NDVI + Entropie Haralick | Random Forest | F-score
moyen : 97.2%



Légende multi-classe

- Batiment
- Couverture forestière / arbre
- Prairie / gazon
- Routes
- Sol nu
- Eau

0 100 200 m

Auteur : Arthur Viry

Sources : Image satellitaire Pléiades, © Airbus Defence & Space, [2016], résolution spatiale 50 cm

Figure 12 : Carte multi-classe avec saisie par points (Bandes + NDVI + Entropy) (QGIS)

Résultats classification binaire

Saisie par polygone

Rang	Attributs	F-score par classe (%)		F-score moyen %	Rang
		Batiments	Non-bati		
T1	Bandes + NDVI + Entropy + MNE	99.2	98.5	98.8	1
T2	Bandes + NDVI + Haralick (sans MNE)	86.5	65.2	75.8	2

Figure 13 : Résultats classification binaire avec échantillonnage par polygone

Dans le cas de la classification binaire des bâtiments par polygones, les résultats montrent une nette amélioration lorsque les attributs sont bien adaptés à la thématique étudiée. La meilleure combinaison, *bandes + NDVI + entropy + MNE*, atteint un F-score moyen de 98,8 %, avec des valeurs très élevées à la fois pour la classe *bâtiments* et pour la classe *non-bâti*. Ce niveau de performance indique que l'approche binaire permet de simplifier efficacement le problème de classification en concentrant l'apprentissage sur une seule opposition thématique.

À l'inverse, la version sans MNE présente un score moyen beaucoup plus faible, ce qui montre que les seules variables spectrales et texturales ne suffisent pas toujours à séparer correctement les objets bâtis du reste de l'environnement. Ce tableau confirme donc que la classification binaire devient particulièrement robuste lorsqu'elle s'appuie sur une donnée complémentaire pertinente.

L'apport du MNE apparaît comme un élément central de l'analyse, en particulier pour la classification binaire des bâtiments. Son intégration provoque un gain très important de performance, puisque le F-score moyen passe de 75,8 % sans MNE à 98,8 % avec MNE. Ce résultat s'explique par le fait que l'information d'élévation permet de mieux distinguer les bâtiments d'autres surfaces artificialisées ou minérales qui peuvent présenter une réponse spectrale proche.

Le MNE apporte donc une dimension structurale que les variables radiométriques seules ne capturent pas entièrement. Dans ce travail, il constitue ainsi l'attribut exogène le plus discriminant, et son utilisation renforce fortement la fiabilité de la cartographie finale.

Carte binaire avec saisie par polygone (Bandes + NDVI + Entropy + MNE)

Classification binaire Bâtiments — Echantillonnage par polygones avec MNE
Attributs : bandes spectrales + NDVI + Entropie Haralick, Contraste Haralick et
Dissimilarité Haralick + Hauteur | Random Forest | F-score bâti : 99.2%



Légende binaire

- Batiment
- Autre

0 100 200 m

Auteur : Arthur Viry

Sources : Image satellitaire Pléiades, © Airbus Defence & Space, [année de prise de vue], résolution spatiale 50 cm
Modèle Numérique d'Élévation (MNE) Raster Bâtiments, Université de Strasbourg, R. Wenger, 2026

Figure 14 : Carte binaire avec saisie par polygone (Bandes + NDVI + Entropy + MNE) (QGIS)

Carte binaire avec saisie par polygone (Bandes + NDVI + Entropy)

Classification binaire Bâtiments — Echantillonnage par polygones
Attributs : bandes spectrales (4)+ NDVI + Entropie Haralick, Contraste Haralick et
Dissimilarité Haralick| Random Forest | F-score bâti : 90.0%



Légende binaire

- Batiment
- Autre

0 100 200 m



Auteur : Arthur Viry

Sources : Image satellitaire Pléiades, © Airbus Defence & Space, [2016], résolution spatiale 50 cm

Figure 15 : Carte binaire avec saisie par polygone (Bandes + NDVI + Entropy) (QGIS)

Saisie par points

Rang	Attributs	F-score par classe (%)		F-score moyen %	Rang
		Batiment	Autre		
T6	Bandes + NDVI + Haralick	90	90	90	1
T2	Bandes + Contraste	90	90	90	2
T3	Bandes + NDVI + Entropy	85	85	85	3
T4	Bandes + NDVI	85.7	84.2	85	4
T5	Bandes + Entropy	85	85	85	5
T6	Bandes + Dissimilarite	85	85	85	6
T7	Bandes seules	81	78.9	80	7

Figure 16 : Résultats classification binaire avec échantillonnage par points

La classification binaire réalisée à partir d'un échantillonnage par points donne des résultats globalement bons, avec un meilleur F-score moyen de 90 % pour les combinaisons *bandes + NDVI + Haralick* et *bandes + contraste*. Les scores obtenus sont équilibrés entre la classe *bâtiments* et la classe *non-bâti*, ce qui montre que le modèle parvient à limiter les déséquilibres entre détection et rejet. L'ajout d'attributs texturaux améliore ici la discrimination des formes bâties par rapport aux bandes seules, ce qui est cohérent avec la logique de l'approche objet.

Néanmoins, comme pour la multi-classe en points, la taille réduite de l'échantillon de validation impose une certaine prudence dans l'interprétation des résultats. Ces performances restent donc encourageantes, mais elles doivent être replacées dans le contexte d'une validation plus légère que celle fondée sur les polygones.

Carte binaire avec saisie par points (Bandes + Haralick)

Classification binaire Bâtiments — Echantillonnage par points

Attributs : bandes spectrales + NDVI + Entropie Haralick, Contraste Haralick et
Dissimilarité Haralick | Random Forest | F-score bâti : 90.0%



Légende binaire

- Batiment
- Autre

0 100 200 m

Auteur : Arthur Viry

Sources : Image satellitaire Pléiades, © Airbus Defence & Space, [2016], résolution spatiale 50 cm

Figure 17 : Carte binaire avec saisie par points (Bandes + Haralick) (QGIS)

Validation OCS

VALIDATION OCS — Multi-classe POLYGONES (NDVI+Entropy) F-score interne : 80.1%								
	Bati	Foret	Prairie	Route	Sol nu	Eau	Rappel	F-score
Bati	1345152	599689	415548	60065	92406	4242	53.4%	65.2%
Foret	242	204250	2679	0	373	2811	97.1%	26.0%
Prairie	20460	493177	132263	1186	29408	3179	19.5%	20.9%
Route	226043	30504	32490	105760	10079	524	26.1%	36.9%
Sol nu	10943	2941	4530	116	6070	0	24.7%	7.5%
Eau	3634	30680	351	0	8	128197	78.7%	84.9%
Precision	83.7%	15.0%	22.5%	63.3%	4.4%	92.3%		Moy: 40.2%

Figure 18 : Résultats validation OCSFE Grand-Est avec la Carte Multiclasse par échantillonnage par polygone (NDVI + Entropy)

La confrontation avec l'OCS Grand Est révèle des performances sensiblement inférieures à la validation interne (40.2% contre 80.1%). La classe Eau obtient le meilleur F-score (84.9%), ce qui s'explique par une définition stable et univoque entre les deux référentiels. À l'inverse, la Forêt présente un rappel très élevé (97.1%) mais une précision médiocre (15.0%), indiquant que le modèle détecte bien la végétation arborée mais l'étend à des surfaces que l'OCS catégorise différemment. La classe Sol nu est la plus pénalisée (7.5%), car ce type d'occupation est peu représenté dans l'OCS, dont la nomenclature regroupe ces surfaces sous des postes plus larges.

VALIDATION OCS — Multi-classe POINTS (NDVI+Entropy) F-score interne : 97.2%								
	Bati	Foret	Prairie	Route	Sol nu	Eau	Rappel	F-score
Bati	842561	498284	454175	299881	329648	92553	33.5%	48.1%
Foret	360	195545	4823	65	321	9241	93.0%	31.4%
Prairie	24107	287470	308677	3150	24985	31284	45.4%	41.6%
Route	111132	22453	31423	210418	18145	11829	51.9%	45.6%
Sol nu	7882	2539	5136	3492	5506	45	22.4%	2.7%
Eau	3676	27703	566	229	256	130440	80.1%	59.5%
Precision	85.1%	18.9%	38.4%	40.7%	1.5%	47.4%		Moy: 38.1%

Figure 19 : Résultats validation OCSFE Grand-Est avec la Carte Multiclasse par échantillonnage par points (NDVI + Entropy)

Les résultats issus du jeu de points sont légèrement inférieurs au jeu de polygones (38.1% contre 40.2%), confirmant la moins grande robustesse de cet échantillonnage. On note néanmoins une meilleure performance sur Prairie (41.6% contre 20.9%) et Route (45.6% contre 36.9%), ce qui suggère que les deux classifications produisent des cartographies légèrement différentes, chacune avec ses propres confusions. La classe Sol nu reste quasi nulle (2.7%), problème commun aux deux classifications face à l'OCS.

Discussion

Protocole de tests

Le protocole de huit tests conduit sur le jeu de polygones montre que la combinaison bandes spectrales, NDVI et entropie de Haralick constitue la meilleure configuration avec un F-score de 80.1%. L'ajout progressif d'indices exogènes n'améliore pas systématiquement les résultats — l'introduction du NDVI seul dégrade même les performances — ce qui confirme que la redondance d'information peut nuire à la classification autant qu'y contribuer. L'entropie de Haralick apporte en revanche une information texturale complémentaire aux bandes spectrales, particulièrement utile pour différencier les toitures des formations végétales.

Comparaison polygones et points

La comparaison entre les deux stratégies d'échantillonnage met en évidence des écarts significatifs. Si les points donnent des F-scores apparemment élevés (~97%), ceux-ci reposent sur seulement dix points de contrôle par classe, ce qui rend les métriques statistiquement peu fiables — un seul pixel mal classé suffit à faire varier le F-score de dix points. Les polygones, malgré des scores plus modestes, couvrent une variabilité intra-classe plus représentative et produisent une évaluation plus réaliste. Nous recommandons dans tous les cas de privilégier les polygones pour la phase de validation.

Multi-classe vs binaire

Sans MNE, la classification multi-classe obtient un meilleur F-score pour les bâtiments (97%) que la binaire (86%). Ce résultat, contre-intuitif au premier abord, s'explique par le fait qu'en multi-classe, le modèle apprend à distinguer les bâtiments de cinq autres classes spectralement contrastées, ce qui affine la frontière de décision. En binaire, la classe non-bâtiments regroupe des surfaces très hétérogènes (forêt, eau, prairie, route), ce qui complexifie l'apprentissage. L'intégration du MNE inverse ce constat, en portant la binaire à 99.2%, confirmant que l'altitude est le descripteur le plus discriminant pour les bâtiments.

Validation externe OCS

L'écart entre validation interne (80.1%) et externe OCS (40.2%) est attendu et s'explique par trois facteurs principaux : des nomenclatures non équivalentes — la classe Sol nu par exemple est quasi absente de l'OCS — un décalage temporel de plusieurs années entre les deux référentiels, et des résolutions de production différentes. La classe Eau reste la mieux reconnue (84.9%) car sa définition est stable entre les deux sources, tandis que Sol nu et Prairie présentent les confusions les plus importantes.

Conclusion

Ce travail nous a permis de mettre en place une chaîne de traitement OBIA complète sur une image Pléiades à 0.5m de résolution, depuis la segmentation jusqu'à la validation statistique des classifications produites. Le meilleur protocole multi-classe, associant bandes spectrales, NDVI et entropie de Haralick, atteint un F-score moyen de 80.1% sur le jeu de polygones.

L'apport le plus notable de ce travail concerne l'intégration du MNE en classification binaire, qui fait progresser la détection des bâtiments de 86% à 99.2%. Ce résultat souligne l'intérêt des données altimétriques pour lever les ambiguïtés spectrales entre bâti et surfaces minérales en milieu urbain dense.

La confrontation avec l'OCS Grand Est a mis en évidence les limites d'une comparaison inter-référentiels, avec des F-scores de l'ordre de 40%, essentiellement imputables aux différences de nomenclature et de date d'acquisition entre les deux sources. En perspective, l'augmentation des effectifs de contrôle et l'intégration d'un MNE végétation constitueraient des pistes d'amélioration pertinentes.

Bibliographie

Blaschke, T. (2010). Object based image analysis for remote sensing. *ISPRS Journal of Photogrammetry and Remote Sensing*, 65(1), 2–16. <https://doi.org/10.1016/j.isprsjprs.2009.06.004>

Blaschke, T., Hay, G. J., Kelly, M., Lang, S., Hofmann, P., Addink, E., Feitosa, R. Q., van der Meer, F., van der Werff, H., van Coillie, F., & Tiede, D. (2014). Geographic Object-Based Image Analysis – Towards a new paradigm. *ISPRS Journal of Photogrammetry and Remote Sensing*, 87, 180–191. <https://doi.org/10.1016/j.isprsjprs.2013.09.014>